

Phân bố Inter-Token-Latency (ITL): dual1.0 vs opt-xxx
ITL của opt-xxx có đuôi dài hơn do GPU bị predictor pause định kỳ

