


dual1.0: GPU time breakdown + CPU OV async (overlay)



Cột = bench duration. Phần ĐỎ = GPU dành cho Llama main model. Phần TÍM = GPU bị predictor sync chiếm. Số xanh phía trên = thời gian CPU OV forward (không nằm trên GPU bar vì chạy song song với phần đỏ).