

Bằng chứng overlap: # Llama iteration chạy trong khi predictor đang chạy
GPU sync luôn = 0 (block GPU). CPU OV có thể > 0 (Llama vẫn forward song song)

