


Bảng chứng định lượng: CPU OV cho phép Llama chạy SONG SONG (cam) — nếu route GPU sẽ mất bấy nhiêu thời gian (tím)



Cam (Llama overlap với CPU OV) = thời gian Llama đã thực sự decode SONG SONG khi predictor đang chạy. Đây là 'work miễn phí' về scheduling cost — không thể có nếu dùng GPU sync.