



Bằng chứng định lượng từ ITL: GPU bị predictor block làm chậm mỗi token

Mỗi token opt-xxx chậm hơn dual1.0 bao nhiêu?



Tổng GPU time bị 'mất' trong opt-xxx vs dual1.0
≈ Tổng thời gian Llama bị predictor block



Mean ITL chênh × số token = tổng thời gian GPU 'lãng phí'. Đây là phần TPOT cải thiện trực tiếp do CPU OV overlap (không block GPU).