


Bằng chứng KEY: CPU overlap thêm ≈ 0ms vào cycle. GPU sync thêm 30-240ms (≈ thời lượng predictor)
Cycle time = ITL ≈ TPOT → CPU OV không tăng TPOT, GPU sync TĂNG TPOT mỗi lần nó chạy



Phương pháp: từ trace dual1.0, phân loại mỗi cặp model_executor[i]→model_executor[i+1] theo predictor event trong gap. 'clean' = không có predictor (baseline). Δ = cycle_avg(category) − cycle_avg(clean). Δ_cpu_ov ≈ 0 → CPU overlap KHÔNG cản GPU. Δ_gpu_sync > 0 → GPU bị block.