

GPU forward time hidden per CPU call (ms)

med 24 ms
 Σ 1.8 s

med 40 ms
 Σ 5.4 s

med 39 ms
 Σ 6.5 s

med 83 ms
 Σ 3.7 s

med 109 ms
 Σ 0.2 s

r = 2

r = 4

r = 8

r = 16

r = 32

Request rate (req/s)

